

****NOTA:**** Analisi e visualizzazioni generate escludendo le righe contrassegnate come outlier (colonna `is\_outlier`).

Report conclusivo

****Dataset:**** 480 osservazioni dopo la pulizia.

****Valori mancanti:**** superficie_sqm = 42, prezzo_mensile = 5, distanza_ateneo_km = 0 ("vicino" mappato a 0.5 km durante il cleaning).

****Outlier:**** 6 record contrassegnati come outlier (metodo IQR su variabili numeriche).

Principali insight:

****Tipo di alloggio è il driver principale del prezzo.**** La regressione OLS (prezzo ~ superficie + distanza + tipo) mostra coefficiente negativo e statisticamente significativo per `posto\_letto` (-658.87, $p < 0.001$) e `singola` (-502.00, $p < 0.001$) rispetto al riferimento (monolocale). Ciò significa che, a parità delle altre variabili, i monolocali costano mediamente molto di più.

****Superficie e distanza non risultano significative**** nel modello lineare semplice utilizzato (coefficiente superficie ≈ 0.039 , $p \approx 0.836$; distanza non significativa). L' R^2 del modello è circa 0.265 (Adj. R^2 0.258), quindi il modello spiega il 26.5% della variabilità del prezzo con le variabili incluse.

Implicazioni operative:

Per attività di pricing o stime veloci, il `tipo\_alloggio` è la variabile più utile da considerare. Una strategia di prezzo segmentata per tipologia (monolocale vs singola vs posto letto) è raccomandata.

Ulteriori miglioramenti: includere variabili aggiuntive (es. arredamento, piano, servizi, vicinanza a trasporti) e utilizzare modelli non lineari o di tree-based per catturare relazioni più complesse.

Artefatti generati (cartella `112`):

`affitti\_studenti\_cleaned\_tidy.csv`: dataset pulito e tidy.

`figures/`: grafici EDA (istogramma prezzo, boxplot prezzo per tipo, scatter prezzo vs superficie, heatmap correlazioni).

`regression\_summary.txt`: sommario completo della regressione OLS.

Report conclusivo

****Dataset:**** 480 osservazioni dopo la pulizia.

****Valori mancanti:**** superficie_sqm = 42, prezzo_mensile = 5, distanza_ateneo_km = 0 ("vicino" mappato a 0.5 km durante il cleaning).

****Outlier:**** 6 record contrassegnati come outlier (metodo IQR su variabili numeriche).

Principali insight:

****Tipo di alloggio è il driver principale del prezzo.**** La regressione OLS (prezzo ~ superficie + distanza + tipo) mostra coefficiente negativo e statisticamente significativo per `posto\_letto` (-658.87, $p < 0.001$) e `singola` (-502.00, $p < 0.001$) rispetto al riferimento (monolocale). Ciò significa che, a parità delle altre variabili, i monolocali costano mediamente molto di più.

****Superficie e distanza non risultano significative**** nel modello lineare semplice utilizzato (coefficiente superficie ≈ 0.039 , $p \approx 0.836$; distanza non significativa). L' R^2 del modello è circa 0.265 (Adj. R^2 0.258), quindi il modello spiega il 26.5% della variabilità del prezzo con le variabili incluse.

Implicazioni operative:

Per attività di pricing o stime veloci, il `tipo\_alloggio` è la variabile più utile da considerare. Una strategia di prezzo segmentata per tipologia (monolocale vs singola vs posto letto) è raccomandata.

Ulteriori miglioramenti: includere variabili aggiuntive (es. arredamento, piano, servizi, vicinanza a trasporti) e utilizzare modelli non lineari o di tree-based per catturare relazioni più complesse.

Artefatti generati (cartella `112`):

`affitti\_studenti\_cleaned\_tidy.csv`: dataset pulito e tidy.

`figures/`: grafici EDA (istogramma prezzo, boxplot prezzo per tipo, scatter prezzo vs superficie, heatmap correlazioni).

`regression\_summary.txt`: sommario completo della regressione OLS.

****NOTA:**** Analisi e visualizzazioni generate escludendo le righe contrassegnate come outlier (colonna `is\_outlier`).

Report tecnico: processo di pulizia e analisi

Obiettivo: pulire e trasformare il dataset in formato tidy, svolgere EDA, condurre analisi quantitative e produrre deliverable replicabili.

1) File di origine

`02\_affitti\_studenti\_tidy.csv` (fornito nella root del progetto).

2) Azioni di cleaning effettuate

Normalizzazione nomi colonne: rimozione spazi accidentali.

Parsing date: `data\_inserimento` convertita a tipo datetime (errori -> NA).

`superficie\_mq`: convertita a numerico; valori ≤ 0 (compresi negativi e zero) trattati come NA.

`distanza\_ateneo\_km`: pulita con regex; valori testuali "vicino" mappati a 0.5 km (scelta motivata da rappresentare una prossimità urbana); formati con suffisso "km" o numeri raw estratti come float.

`prezzo\_mensile`: convertito a numerico; valori ≤ 0 trattati come NA.

`tipo\_alloggio`: normalizzato in categorie coerenti (`monolocale`, `singola`, `posto\_letto`), rimozione spazi e punteggiatura, lowercasing.

Creazione colonna `cleaning\_notes` che riporta per riga azioni rilevanti (es. valori mancanti o outlier).

3) Rilevazione outlier

Metodo: IQR ($1.5 * IQR$) applicato separatamente a `superficie\_mq`, `prezzo\_mensile` e `distanza\_ateneo\_km`.

Righe con almeno una variabile fuori soglia vengono contrassegnate come `is\_outlier`.

Totale outlier rilevati: 6.

4) Formato tidy

Il dataset pulito salvato in `112/affitti\_studenti\_cleaned\_tidy.csv` è tidy: ogni riga è un annuncio (`id\_annuncio`), ogni variabile in una colonna separata. Le colonne principali: `id\_annuncio`, `data\_inserimento`, `superficie\_mq`, `distanza\_ateneo\_km`, `prezzo\_mensile`, `tipo\_alloggio`, `is\_outlier`, `cleaning\_notes`.

5) EDA e visualizzazioni

Grafici generati e salvati in `112/figures/`:

- `hist\_prezzo.png`: distribuzione del prezzo mensile.
- `box\_prezzo\_tipo.png`: boxplot del prezzo per tipologia di alloggio.
- `scatter\_prezzo\_superficie.png`: scatter prezzo vs superficie colorato per tipo.
- `heatmap\_corr.png`: matrice di correlazione delle variabili numeriche.

6) Analisi statistica

Modello stimato: regressione OLS con `prezzo\_mensile` come variabile dipendente e regressori `superficie\_mq`, `distanza\_ateneo\_km` e dummy per `tipo\_alloggio` (monolocale come riferimento, dummies drop_first).

Osservazioni usate nel modello: 434 (righe con `prezzo\_mensile` e `superficie\_mq` non missing).

Risultati principali (vedi `regression\_summary.txt`):

- $R^2 = 0.265$, Adj. $R^2 = 0.258$.
- Coefficienti significativi ($p < 0.001$): `tipo\_posto\_letto` = -658.87, `tipo\_singola` = -502.00.
- `superficie\_mq` e `distanza\_ateneo\_km` non risultano statisticamente significative nel modello lineare semplice adottato.

7) Motivazioni e limiti metodologici

Scelte conservative: valori non plausibili (negativi o zero) trattati come mancanti per evitare bias.

La mappatura di "vicino" a 0.5 km è una assunzione pragmatica; è documentata nel codice e può essere modificata se sono disponibili regole più precise.

Il metodo IQR è semplice e robusto; per analisi approfondite si potrebbero usare metodi basati su modello o robust regression per evitare rimozioni arbitrarie.

Il modello OLS è un primo approccio descrittivo; la bassa R^2 indica la necessità di includere feature aggiuntive o usare modelli non lineari.

8) File e script prodotti

`112/clean\_and\_analyze.py`: script completo che esegue pulizia, EDA e stima regressione.

`112/affitti\_studenti\_cleaned\_tidy.csv`: dataset pulito e tidy.

`112/figures/\*`: grafici generati.

`112/regression\_summary.txt`: output testo del sommario della regressione.

`112/report\_conclusivo.md`, `112/report\_tecnico.md`: i due report (questo è il tecnico).

9) Come replicare

Attivare l'ambiente virtuale e installare dipendenze:

```
...
```

```
.venv\Scripts\Activate.ps1
```

```
.venv\Scripts\python -m pip install -r 112/requirements.txt
```

```
...
```

Eseguire lo script:

```
...
```

```
.venv\Scripts\python "112/clean_and_analyze.py"
```

```
...
```

10) Prossimi passi raccomandati

Arricchire il dataset con variabili descrittive dell'annuncio (arredamento, stanze, piano, foto) e contesto (vicinanza a mezzi, servizi).

Prove con modelli tree-based (Random Forest, XGBoost) e validazione incrociata per migliorare capacità predittiva.

Analisi del prezzo per cluster di posizione geografica (se disponibile la lat/lon).

Report tecnico: processo di pulizia e analisi

Obiettivo: pulire e trasformare il dataset in formato tidy, svolgere EDA, condurre analisi quantitative e produrre deliverable replicabili.

1) File di origine

`02\_affitti\_studenti\_tidy.csv` (fornito nella root del progetto).

2) Azioni di cleaning effettuate

Normalizzazione nomi colonne: rimozione spazi accidentali.

Parsing date: `data\_inserimento` convertita a tipo datetime (errori -> NA).

`superficie\_mq`: convertita a numerico; valori ≤ 0 (compresi negativi e zero) trattati come NA.

`distanza\_ateneo\_km`: pulita con regex; valori testuali "vicino" mappati a 0.5 km (scelta motivata da rappresentare una prossimità urbana); formati con suffisso "km" o numeri raw estratti come float.

`prezzo\_mensile`: convertito a numerico; valori ≤ 0 trattati come NA.

`tipo\_alloggio`: normalizzato in categorie coerenti (`monolocale`, `singola`, `posto letto`), rimozione spazi e punteggiatura, lowercasing.

Creazione colonna `cleaning\_notes` che riporta per riga azioni rilevanti (es. valori mancanti o outlier).

3) Rilevazione outlier

Metodo: IQR ($1.5 * IQR$) applicato separatamente a `superficie\_mq`, `prezzo\_mensile` e `distanza\_ateneo\_km`.

Righe con almeno una variabile fuori soglia vengono contrassegnate come `is\_outlier`.

Totale outlier rilevati: 6.

4) Formato tidy

Il dataset pulito salvato in `112/affitti\_studenti\_cleaned\_tidy.csv` è tidy: ogni riga è un annuncio (`id\_annuncio`), ogni variabile in una colonna separata. Le colonne principali: `id\_annuncio`, `data\_inserimento`, `superficie\_mq`, `distanza\_ateneo\_km`, `prezzo\_mensile`, `tipo\_alloggio`, `is\_outlier`, `cleaning\_notes`.

5) EDA e visualizzazioni

Grafici generati e salvati in `112/figures/`:

- `hist\_prezzo.png`: distribuzione del prezzo mensile.
- `box\_prezzo\_tipo.png`: boxplot del prezzo per tipologia di alloggio.
- `scatter\_prezzo\_superficie.png`: scatter prezzo vs superficie colorato per tipo.
- `heatmap\_corr.png`: matrice di correlazione delle variabili numeriche.

6) Analisi statistica

Modello stimato: regressione OLS con `prezzo\_mensile` come variabile dipendente e regressori `superficie\_mq`, `distanza\_ateneo\_km` e dummy per `tipo\_alloggio` (monocale come riferimento, dummies drop_first).

Osservazioni usate nel modello: 434 (righe con `prezzo\_mensile` e `superficie\_mq` non missing).

Risultati principali (vedi `regression\_summary.txt`):

- $R^2 = 0.265$, Adj. $R^2 = 0.258$.
- Coefficienti significativi ($p < 0.001$): `tipo\_posto letto` = -658.87, `tipo\_singola` = -502.00.
- `superficie\_mq` e `distanza\_ateneo\_km` non risultano statisticamente significative nel modello lineare semplice adottato.

7) Motivazioni e limiti metodologici

Scelte conservative: valori non plausibili (negativi o zero) trattati come mancanti per evitare bias.

La mappatura di "vicino" a 0.5 km è una assunzione pragmatica; è documentata nel codice e può essere modificata se sono disponibili regole più precise.

Il metodo IQR è semplice e robusto; per analisi approfondite si potrebbero usare metodi basati su modello o robust regression per evitare rimozioni arbitrarie.

Il modello OLS è un primo approccio descrittivo; la bassa R^2 indica la necessità di includere feature aggiuntive o usare modelli non lineari.

8) File e script prodotti

`112/clean\_and\_analyze.py`: script completo che esegue pulizia, EDA e stima regressione.

`112/affitti\_studenti\_cleaned\_tidy.csv`: dataset pulito e tidy.

`112/figures/\*`: grafici generati.

`112/regression\_summary.txt`: output testo del sommario della regressione.

`112/report\_conclusivo.md`, `112/report\_tecnico.md`: i due report (questo è il tecnico).

9) Come replicare

Attivare l'ambiente virtuale e installare dipendenze:

```
...
```

```
.venv\Scripts\Activate.ps1
```

```
.venv\Scripts\python -m pip install -r 112/requirements.txt
```

```
...
```

Eseguire lo script:

```
...
```

```
.venv\Scripts\python "112/clean_and_analyze.py"
```

```
...
```

10) Prossimi passi raccomandati

Arricchire il dataset con variabili descrittive dell'annuncio (arredamento, stanze, piano, foto) e contesto (vicinanza a mezzi, servizi).

Prove con modelli tree-based (Random Forest, XGBoost) e validazione incrociata per migliorare capacità predittiva.

Analisi del prezzo per cluster di posizione geografica (se disponibile la lat/lon).

Report dettagliato delle analisi

Dataset

Osservazioni usate: 428

Correlazioni (Pearson)

Vedi `corr\_heatmap.png` e `corr\_pearson.csv`.

Regressione lineare OLS

Sommario completo in `regression\_detail\_summary.txt`.

VIF in `vif.csv`.

Residual tests: `residuals\_tests.txt`, `breusch\_pagan.txt`.

Random Forest

CV R2 in `rf\_cv\_scores.txt`. Feature importances in `rf\_feature\_importances.csv` e `rf\_feature\_importances.png`.

regression_summary_no_outliers.txt

OLS Regression Results

```
=====
Dep. Variable:    prezzo_mensile  R-squared:    0.991
Model:            OLS  Adj. R-squared:    0.991
Method:           Least Squares  F-statistic:    1.163e+04
Date:            Wed, 03 Jun 2026  Prob (F-statistic):    0.00
Time:            10:40:20  Log-Likelihood:    -2086.7
No. Observations:    428  AIC:    4183.
Df Residuals:        423  BIC:    4204.
Df Model:            4
Covariance Type:    nonrobust
=====
```

```
=====
              coef  std err          t  P>|t|  [0.025   0.975]
-----
const          224.8246   10.480    21.453   0.000   204.225   245.424
superficie_mq    15.0011    0.210    71.409   0.000    14.588    15.414
distanza_ateneo_km -0.3579    1.067   -0.336   0.737   -2.455    1.739
tipo_posto_letto -204.4178    8.248  -24.783   0.000  -220.630  -188.205
tipo_singola     -67.6193    7.150   -9.458   0.000   -81.673   -53.566
=====
```

```
=====
Omnibus:          3.016  Durbin-Watson:    2.029
Prob(Omnibus):    0.221  Jarque-Bera (JB):    2.356
Skew:             -0.012  Prob(JB):    0.308
Kurtosis:         2.637  Cond. No.    305.
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

regression_summary.txt

OLS Regression Results

```
=====
Dep. Variable:    prezzo_mensile  R-squared:    0.265
Model:            OLS  Adj. R-squared:    0.258
Method:           Least Squares  F-statistic:    38.64
Date:            Wed, 03 Jun 2026  Prob (F-statistic):    1.26e-27
Time:            10:32:12  Log-Likelihood:    -3297.3
=====
```

No. Observations: 434 AIC: 6605.
Df Residuals: 429 BIC: 6625.
Df Model: 4
Covariance Type: nonrobust

	coef	std err	t	P> t	[0.025	0.975]
const	930.0927	52.032	17.875	0.000	827.823	1032.362
superficie_mq	0.0387	0.187	0.208	0.836	-0.328	0.405
distanza_ateneo_km	0.0367	16.117	0.002	0.998	-31.641	31.714
tipo_posto_letto	-658.8721	57.495	-11.460	0.000	-771.879	-545.865
tipo_singola	-502.0002	57.297	-8.761	0.000	-614.618	-389.382

Omnibus: 1007.247 Durbin-Watson: 2.014

Prob(Omnibus): 0.000 Jarque-Bera (JB): 2615898.909

Skew: 18.907 Prob(JB): 0.00

Kurtosis: 381.455 Cond. No. 433.

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.



