


Documentazione del Processo Analitico

Affitti Studenti — Data Cleaning · EDA · Analisi Statistica

1 · Pipeline del Progetto



2 · Fase 1 — Lettura e Prima Ispezione

Strumenti utilizzati

La lettura del file è avvenuta tramite `pandas.read_excel()`, che ha correttamente interpretato la colonna `Data_Inserimento` come `datetime64`. La colonna `Distanza_Ateneo_KM` è stata letta come `object` a causa della presenza di valori testuali misti ("vicino", "4.1km", "2.3 km", ecc.).

Problemi identificati in fase di ispezione

Problema	Dettaglio	Quantità	Gravità
Righe completamente vuote	Righe NaN su tutte le colonne (padding del file)	57	Alta
ID duplicati	Stessa ID_Annuncio con medesimi valori (duplicazione esatta)	15 coppie	Alta
Distanza testuale mista	"vicino", " 4.1km ", "2.3 km", float nudo	tutti i 552	Media
Tipo_Alloggio inconsistente	22 varianti dello stesso valore (UPPER, lower, spazi)	22 varianti	Media
Superficie negativa (-10)	Codice sentinella/errore di inserimento	8	Media
Superficie 1200 m²	Valore impossibile per alloggio singolo studente	5	Alta
Superficie = 0	Valore mancante codificato come zero	3	Media
Prezzo negativo (-450)	Codice sentinella o errore	4	Alta
Prezzo = 0	Valore mancante o annuncio gratuito non valido	1	

Prezzo = 9999	Placeholder "prezzo da concordare"	1	Media
Superficie NaN	Valori mancanti reali	47 finali	Bassa

3 · Fase 2 — Pulizia dei Dati

Passo 1: Rimozione righe vuote

Problema: 57 righe completamente vuote nel file sorgente, con indici non consecutivi. Probabilmente introdotte come separatori visivi nel foglio Excel originale.

Soluzione: `df.dropna(how='all')` — rimozione di tutte le righe in cui ogni cella è NaN. Nessuna perdita di informazione.

Passo 2: Gestione duplicati

Problema: 15 ID_Annuncio presenti in duplice copia con valori identici su tutte le colonne. Causa probabile: errore di importazione da sorgente o doppia esportazione.

Decisione metodologica: `drop_duplicates(subset='ID_Annuncio', keep='first')`. Poiché i duplicati erano esatti (stesso valore su tutte le colonne), la scelta di mantenere il primo record è arbitraria ma equivalente. Non si sono conservate entrambe le copie per evitare di distorcere le statistiche descrittive.

Passo 3: Normalizzazione Tipo_Alloggio

Problema: La stessa categoria era presente in 22 varianti: "MONOCALE", "monocale", " monocale", "Monocale", " Monocale ", ecc. Stessa situazione per "singola"/"SINGOLA"/"Stanza Singola"/"stanza singola"/" Stanza Singola". La varianza era interamente formale, non semantica.

Soluzione: Funzione di mapping basata su `str.contains()` con lookup case-insensitive sui pattern chiave: "monocale", "singola", "posto letto". Tutte le 480 righe residue hanno ottenuto una categoria valida. Zero valori non classificati.

```
def normalize_tipo(val):
    v = str(val).strip().lower()
    if 'monocale' in v: return 'Monocale'
    elif 'singola' in v: return 'Stanza Singola'
    elif 'posto letto' in v: return 'Posto Letto'
```

Passo 4: Parsing Distanza_Ateneo_KM

Problema: La colonna conteneva formati eterogenei: float nudo (2.5), stringa con unità ("3.1 km", "3.9km "), valore semantico ("vicino"), e float con floating-point imprecision ("4.9000000000000004").

Decisione metodologica — "vicino": Abbiamo assegnato il valore convenzionale di **0.3 km**. Motivazione: i valori numerici più piccoli nel dataset sono 0.1 km e 0.2 km; "vicino" implica distanza pedonale breve, stimabile a ≤ 5 minuti a piedi. Il valore 0.3 km è una stima conservativa ma coerente con il contesto. Alternativa scartata: imputazione con la mediana del gruppo — avrebbe perso l'informazione semantica.

Soluzione: Regex `(\d+(?:\.\d+)?)` applicata alla stringa ripulita, con caso speciale per "vicino". Round a 1 decimale per eliminare artefatti floating-point. Zero NaN residui.

Passo 5: Correzione Superficie_MQ

Problema: Tre tipologie di valori errati: (a) -10 (codice sentinella, 8 casi), (b) 1200 m² (impossibile per singola unità studentesca, 5 casi), (c) 0 m² (missing codificato, 3 casi).

Decisione: Tutti e tre i pattern → impostati a NaN. Non si è tentata l'imputazione statistica (es. media per tipo) per non introdurre valori sintetici che potrebbero distorcere l'analisi di regressione. I 47 NaN finali rappresentano il 9.8% della colonna: accettabile per un'analisi esplorativa.

Passo 6: Correzione Prezzo_Mensile

Problema: Quattro record con prezzo -450 (codice sentinella, probabilmente "non disponibile"), uno con prezzo 0 (annuncio non compilato), uno con prezzo 9999 (placeholder "da concordare").

Soluzione: Tutti impostati a NaN. Nessun tentativo di recupero perché non c'è modo di derivare il prezzo corretto da altre variabili. 6 NaN residui su 480 (1.2%): trascurabili.

4 · Fase 3 — Analisi Esplorativa (EDA)

Approccio

L'EDA è stata strutturata in tre livelli: (1) statistiche descrittive univariate, (2) distribuzioni e boxplot per categoria, (3) relazioni bivariate e multivariabili. Le visualizzazioni sono state progettate con palette cromatica coerente: **blu per Monolocale**, **viola per Stanza Singola**, **arancio per Posto Letto**.

Strumenti

pandas per aggregazioni e pivot table · **seaborn** per boxplot, heatmap e scatter · **matplotlib** per layout custom · **scipy.stats** per KDE e test statistici.

Principali osservazioni EDA

Variabile	Osservazione	Azione
Prezzo_Mensile	Distribuzione multimodale (3 picchi per i 3 tipi). Assenza di outlier severi dopo cleaning.	Analisi separata per tipo
Superficie_MQ	Forte bimodalità: cluster 9-25 m² (posti letto/singole) e 30-65 m² (monolocali)	Variabile chiave in regressione
Distanza_Ateneo_KM	Distribuzione quasi uniforme 0-6 km. Nessun cluster geografico evidente.	Analisi per fascia
Data_Inserimento	Picco a febbraio-marzo, coda lunga verso aprile	Analisi stagionalità

5 · Fase 4 — Analisi Statistica

Scelta dei test: parametrici vs non-parametrici

Motivazione: Le distribuzioni di prezzo per tipo non sono normali (verifica visiva dalle KDE: distribuzione del Posto Letto quasi rettangolare, Stanza Singola campaniforme asimmetrica). Per il confronto tra i tre gruppi è stato scelto il **test di Kruskal-Wallis** (alternativa non-parametrica all'ANOVA one-way), seguito dai **test post-hoc di Mann-Whitney** con correzione di Bonferroni ($\alpha = 0.0167$ per 3 confronti).

Scelta del modello di regressione

Motivazione: La forte linearità osservata nel scatter Superficie↔Prezzo (visiva e confermata da $r=0.98$) giustifica l'uso della **regressione lineare OLS semplice**. Non si è ricorso a modelli polinomiali o ridge perché: (a) il grafico dei residui non mostra pattern sistematici, (b) l' R^2 è già a saturazione (0.965), (c) aggiungere complessità non apporterebbe valore interpretativo. La varianza residua (~3.5%) è attribuibile alla variabili non osservate (zona, servizi inclusi).

Confounding nella distanza

Problema identificato: La correlazione globale distanza↔prezzo ($r=-0.18$) sembrava suggerire un effetto prezzo per vicinanza. L'analisi stratificata per tipo ha rivelato che questo è un effetto di confounding: i monolocali sono sovra-rappresentati nelle fasce di distanza basse (distanza media 2.04 km

vs 2.82 km dei posti letto).

Soluzione analitica: Analisi della regressione intra-gruppo. Risultato: $\beta_{\text{Posto Letto}} = -1.9 \text{ €/km}$ ($p=0.174 \text{ ns}$), $\beta_{\text{Stanza Singola}} = -1.7 \text{ €/km}$ ($p=0.695 \text{ ns}$), $\beta_{\text{Monolocale}} = -2.0 \text{ €/km}$ ($p=0.852 \text{ ns}$). Il confounding era interamente spiegabile dalla diversa distribuzione geografica dei tipi di alloggio.

6 • Difficoltà Incontrate e Soluzioni

#	Difficoltà	Soluzione adottata	Alternativa scartata
1	Valore "vicino" non numerico nella colonna distanza (69 casi, 14%)	Assegnazione convenzione 0.3 km basata su semantica e valori minimi del dataset	Imputazione con mediana del tipo (perdita di semantica "vicino")
2	Superficie 1200 m ² — impossibile ma non ovviamente un typo numerico	Analisi del contesto: 5 annunci con superficie 1200 m ² , prezzi incompatibili con tale metratura → sicuramente placeholder	Mantenerla come outlier per analisi di sensibilità
3	Correlazione distanza-prezzo fuorviante senza stratificazione	Analisi intra-gruppo per smascherare il confounding	Reporting della correlazione grezza senza nota metodologica
4	Floating-point noise (es. "4.9000000000000004")	Round a 1 decimale dopo parsing regex	—
5	47 NaN in Superficie_MQ (9.8%) — analisi di regressione parziale	Analisi "complete cases" (433 righe). Verifica MCAR: i NaN sono distribuiti uniformemente tra i tipi → MAR assumption accettabile	Imputazione multipla (sovradimensionata per questo scopo)

7 • Scelte Metodologiche — Riepilogo

Scelta	Motivazione
Kruskal-Wallis + Mann-Whitney (non OLS ANOVA)	Distribuzione non normale delle variabili; test non-parametrici più robusti per n moderato con asimmetria
Regressione OLS semplice (Prezzo ~ Superficie)	Relazione già lineare e saturata a $R^2=0.965$. Parsimonia > complessità.
Analisi intra-gruppo per distanza	Evitare l'errore di Simpson — la correlazione aggregata era fuorviante
Prezzo/m ² come metrica comparativa	Permette confronto equo tra format con superfici molto diverse
Mediana come statistica centrale principale	Distribuzione dei prezzi non normale; mediana è più robusta agli outlier residui
IC 95% con Fisher z-transformation per correlazioni	Stima dell'incertezza statistica su r, non solo del valore puntuale

8 • Output Finali Prodotti

File	Formato	Contenuto
affitti_studenti_clean.xlsx	Excel	Dataset tidy: 480 righe, 6 colonne standardizzate
report_conclusioni.html	HTML	Report narrativo con grafici embedded, stile data storytelling
report_tecnico.html	HTML	Documentazione completa del processo (questo file)
11 grafici PNG	PNG 150dpi	Tutte le visualizzazioni generate durante l'analisi

Struttura del dataset pulito

Colonna	Tipo finale	Valori NaN	Note

ID_Annuncio	string	0	Chiave univoca
Data_Inserimento	datetime64	0	Parsing automatico da Excel serial date
Superficie_MQ	float64	47 (9.8%)	Valori negativi/0/1200 → NaN
Distanza_Ateneo_KM	float64	0	"vicino"→0.3, regex parsing su stringhe
Prezzo_Mensile	float64	6 (1.2%)	Valori <0, 0, 9999 → NaN
Tipo_Alloggio	category (3 livelli)	0	Normalizzato da 22 varianti a 3 categorie